

Notebook 03

EDA de cohorte completa y control de calidad físico

Definiciones, supuestos, fórmulas y justificación metodológica

Alcance

Auditoría física y técnica de los 1.362 estudios. No registra cerebros, no diagnostica y no excluye casos automáticamente.

Contenido

1. Propósito y alcance
2. Terminología fundamental
3. Recorrido celda por celda
4. Interpretación correcta
5. Supuestos y limitaciones
6. Glosario breve

Versión metodológica · 22 de agosto de 2026

1. Propósito y alcance

Este documento describe exclusivamente el notebook `notebooks/03_eda_cohorte_3d_dat.ipynb`. Su función es auditar los 1.362 estudios tridimensionales antes de registrarlos, extraer biomarcadores o entrenar un modelo.


El notebook responde cuatro preguntas:

- 1 ¿Cada archivo puede abrirse y contiene un volumen 3D numéricamente válido?
- 2 ¿Cuál es la geometría física de cada estudio?
- 3 ¿Qué características básicas presenta su señal y su organización espacial?
- 4 ¿Qué casos son técnicamente inusuales y deberían revisarse visualmente?

No diagnostica enfermedad, no segmenta estructuras anatómicas, no registra cerebros entre sí y no elimina estudios automáticamente. Sus scores son herramientas de priorización para control de calidad, no probabilidades clínicas.

Flujo conceptual

Esquema



2. Terminología fundamental

Cohorte completa o full-cohort

Full-cohort no es un término propio de este conjunto de datos ni una categoría de neurociencia. Significa simplemente procesar la cohorte completa. En este proyecto corresponde a los 1.362 estudios disponibles. La configuración que lo activa es:

Extracto de código

```
MAX_SCANS: int | None = None
```

None indica que no se aplica un máximo ni se toma una muestra.

NIfTI y datos raw

Cada `.nii.gz` es un archivo NIfTI que contiene:

- una matriz tridimensional de intensidades;
- dimensiones y tipo de dato;
- spacing o separación física entre vóxeles;
- matrices para relacionar índices de vóxel con coordenadas físicas;
- metadatos de orientación.

En el repositorio se consideran raw porque son los archivos originales entregados por la competencia y el pipeline no los modifica. No son, sin embargo, mediciones crudas del detector: son volúmenes 3D ya reconstruidos.

QC y dominio técnico

QC significa quality control o control de calidad. Busca comportamientos técnicos inusuales: geometrías diferentes, valores inválidos, fragmentación, ruido o incoherencia entre cortes.

Un dominio técnico es un conjunto producido bajo condiciones de adquisición parecidas. Puede reflejar diferencias de scanner, centro, resolución, protocolo o reconstrucción. Como esos metadatos no están necesariamente disponibles, el notebook aproxima el dominio mediante dimensiones y spacing. Un dominio técnico no es una clase clínica.

Vóxel, shape, spacing y FOV

Un vóxel es una posición de la matriz tridimensional. Si un volumen tiene:

Esquema

```
shape = 128 × 128 × 90
```

entonces contiene:

$$128 \times 128 \times 90 = 1\,474\,560 \text{ vóxeles.}$$

El spacing es la separación física entre centros de vóxeles consecutivos. Se mide para cada eje:

Extracto de código

```
spacing_x_mm  
spacing_y_mm  
spacing_z_mm
```

La cobertura física o field of view (FOV) se aproxima en cada dimensión como:

$$FOV_x = shape_x \times spacing_x.$$

Análogamente se calculan FOV_y y FOV_z . El volumen físico de un vóxel es:

$$V_{\text{vóxel}} = spacing_x \times spacing_y \times spacing_z.$$

Proxy

Un proxy es una medición indirecta o aproximada. Por ejemplo, comparar la señal de las dos mitades de la imagen puede sugerir asimetría, pero no equivale a segmentar y comparar los estriados derecho e izquierdo. Los proxies son útiles para explorar y detectar anomalías; no deben interpretarse como biomarcadores anatómicos validados.

3. Recorrido celda por celda

Celda 1: presentación

Declara que se realizará un EDA de cohorte completa con control de calidad físico. EDA significa exploratory data analysis o análisis exploratorio de datos.

La palabra “físico” indica que dimensiones, posiciones y gradientes se interpretan usando milímetros, no solamente índices de una matriz.

Celda 2: contrato metodológico

Documenta antes de ejecutar que:

- se procesará toda la cohorte;
- las fuentes permanecerán intactas;
- los resultados derivados serán privados;
- RAS homogenizará los ejes, pero no registrará anatómicamente los cerebros;
- las métricas serán exploratorias y no producirán exclusiones automáticas.

Este contrato evita atribuir al notebook capacidades que todavía no tiene.

Celda 3: bibliotecas, rutas y configuración

Carga las bibliotecas y define las entradas y salidas:

Extracto de código

```
NIFTI_ARCHIVE = PROJECT_ROOT / "data" / "raw" / "niftis.zip"
LABELS_PATH = PROJECT_ROOT / "data" / "raw" / "train_labels.csv"
PRIVATE_OUTPUT_DIR = PROJECT_ROOT / "outputs" / "private_eda"
```

Los parámetros son:

Parámetro	Definición	Consecuencia
MAX_SCANS=None	Sin máximo de estudios	Procesa los 1.362
RANDOM_SEED=20260821	Semilla reproducible	Sólo actuaría si se tomara una muestra
MIN_PROTOCOL_FAMILY_SIZE=5	Tamaño mínimo de una familia estable	Grupos menores usan referencia global
SAVE_PRIVATE_OUTPUTS=True	Activa persistencia	Guarda manifiestos y configuración

La celda comprueba que existan el ZIP y las etiquetas. Si falta una entrada, detiene la ejecución en lugar de generar resultados incompletos.

Celda 4: identificación, lectura y orientación

Identificación de los archivos

`uid_from_member` extrae el UID desde el nombre del NIfTI. `list_nifti_members` enumera los `.nii` y `.nii.gz` contenidos en el ZIP.

Si `MAX_SCANS` fuera menor que el total, se elegiría una muestra aleatoria sin reemplazo:

Extracto de código

```
rng = np.random.default_rng(RANDOM_SEED)
indices = np.sort(rng.choice(len(members), size=MAX_SCANS, replace=False))
```

Con `MAX_SCANS=None`, ese bloque no se ejecuta. El random no altera las imágenes ni sus intensidades.

Lectura de un volumen

Cada archivo se extrae a un directorio temporal, se carga y se elimina al salir de la función. Se procesa un estudio a la vez para limitar el uso de memoria. Reabrir el ZIP en cada iteración aumenta el costo de entrada/salida, pero conserva un flujo simple y acotado en RAM.

Orientación RAS

RAS significa:

- R: Right, hacia la derecha;
- A: Anterior, hacia el frente;
- S: Superior, hacia arriba.

Extracto de código

```
canonical = nib.as_closest_canonical(image)
```

Esta operación reordena o invierte ejes para que tengan un significado común. No alinea sujetos entre sí ni cambia su resolución física. Su propósito es que “izquierda”, “derecha”, “anterior” y “superior” no dependan de cómo cada archivo fue almacenado.

qform, sform y affine

Los índices (x,y,z) sólo indican una posición dentro de la matriz. La matriz affine los transforma a una posición física:

```
\begin{bmatrix}x\\y\\z\\1\end{bmatrix}_{mm} = A \begin{bmatrix}x\\y\\z\\1\end{bmatrix}_{\text{vóxel}}.
```

NIfTI ofrece dos representaciones de esta relación:

- qform: orientación, escala y posición mediante una representación compacta basada en

cuaterniones;

- sform: transformación affine más general.

qform_code y sform_code indican si cada transformación es válida y su significado previsto. El notebook no decide cuál es clínicamente correcta; conserva ambos códigos para auditoría.

También registra el determinante de la parte espacial de la affine. Un valor casi cero puede indicar una transformación singular o inválida.

Celda 5: contrato del manifiesto

Introduce la construcción de una fila por estudio. La fila resume integridad, geometría, distribución de intensidad, organización espacial y métricas de QC. El conjunto de filas será el manifiesto que consumirán los notebooks posteriores.

Celda 6: métricas por estudio

Integridad numérica

Se identifica qué vóxeles contienen números finitos:

Extracto de código

```
finite_mask = np.isfinite(volume)
```

Se calculan:

- finite_fraction: proporción finita;
- zero_fraction: proporción igual a cero;
- positive_fraction: proporción positiva.

Los ceros suelen representar fondo. Una fracción extrema no demuestra un error, pero puede revelar una reconstrucción o un encuadre diferente.

Percentiles y normalización robusta

Sobre los valores positivos —o todos los finitos si no hay positivos— se calculan \$p01\$, \$p05\$, \$p50\$, \$p90\$, \$p95\$ y \$p99.5\$. La normalización exploratoria es:

$$I_{norm} = \text{clip} \left(\frac{I - p01}{p99.5 - p01}, 0, 1 \right).$$

Los percentiles son menos sensibles a unos pocos valores extremos que el mínimo y el máximo. Utilizar \$p99.5\$ evita que un único vóxel brillante reduzca el contraste efectivo del resto del volumen. Esta normalización vive en memoria; el NIfTI original no se sobrescribe.

Geometría

Se guardan shape, spacing, FOV, volumen del vóxel y anisotropía. Esta última es:

$$\text{anisotropía} = \frac{\max(\text{spacing}_x, \text{spacing}_y, \text{spacing}_z)}{\min(\text{spacing}_x, \text{spacing}_y, \text{spacing}_z)}.$$

Un valor 1 corresponde a vóxeles isotrópicos. Un valor 2 significa que la separación en alguna dirección es dos veces la de otra.

Entropía

safe_entropy distribuye las intensidades en 64 intervalos y calcula:

$$H = - \sum_i p_i \log_2 (p_i).$$

La entropía resume diversidad de intensidades. Es una medición técnica exploratoria, no entropía anatómica ni biomarcador clínico.

Foreground y alta captación

Se define como foreground proxy la región sobre la mediana positiva:

Extracto de código

```
foreground = finite_mask & (volume > p50)
```

Su volumen se expresa en mililitros. No representa el volumen cerebral real porque no utiliza una segmentación anatómica.

La alta captación se define sobre \$p90\$. Se cuentan sus componentes conectados y la fracción perteneciente al mayor. Muchos componentes pequeños pueden indicar fragmentación o ruido; un componente dominante indica señal espacialmente más concentrada. Como el umbral es relativo a cada estudio, describe organización y no intensidad absoluta.

Centroide

El centro de masa se calcula ponderando los vóxeles del foreground por su intensidad normalizada. La affine transforma el resultado a milímetros. Si el cálculo no es finito, se utiliza el centro geométrico del volumen como respaldo.

Asimetría global proxy

Después de orientar a RAS, el volumen se divide por la mitad del eje X. Sean S_D y S_I las sumas ponderadas de ambas mitades:

$$AI_{abs} = \frac{|S_D - S_I|}{(S_D + S_I)/2},$$

$$AI_{signed} = \frac{S_D - S_I}{(S_D + S_I)/2}.$$

La versión absoluta mide magnitud y la versión con signo conserva dirección. Puede alcanzar valores próximos a 2 si toda la señal está en un lado. Sigue siendo un proxy global: puede responder a asimetría biológica, posicionamiento, encuadre o artefactos.

Gradiente físico de intensidad

`np.gradient` aproxima las derivadas espaciales. Para un vóxel interior:

$$\frac{\partial I}{\partial x} \approx \frac{I(x+1, y, z) - I(x-1, y, z)}{2 \text{ spacing}_x},$$

y análogamente para Y y Z. En los bordes utiliza diferencias de un solo lado.

La magnitud tridimensional es:

$$|\nabla I| = \sqrt{\left(\frac{\partial I}{\partial x}\right)^2 + \left(\frac{\partial I}{\partial y}\right)^2 + \left(\frac{\partial I}{\partial z}\right)^2}.$$

Después se promedia dentro de los vóxeles sobre $5 \times 5 \times 5$, para que el fondo negro no domine. La unidad aproximada es intensidad normalizada por milímetro.

La columna histórica se llama `gradient_energy`, pero matemáticamente es la media de la magnitud del gradiente, no energía cuadrática. `gradient_energy_per_mm` expresa mejor su contrato.

Correlación entre cortes

Se calcula la correlación de Pearson entre cada par de cortes Z consecutivos y se conserva la mediana. Cortes constantes se omiten porque su correlación no está definida.

- Valores cercanos a 1: alta semejanza entre cortes vecinos.
- Valores menores: cambios más rápidos, ruido, movimiento o una resolución axial diferente.

La medida depende del protocolo; por eso después se compara preferentemente dentro de familias técnicas.

Procesamiento y etiquetas

Cada archivo se procesa dentro de un try/except: un fallo queda registrado, pero no cancela toda la cohorte. Al final se incorporan las etiquetas mediante UID con validación uno-a-uno. Las etiquetas no intervienen en el cálculo de métricas ni en la creación de familias.

Celda 7: motivación de las familias técnicas

Introduce el problema de comparar adquisiciones heterogéneas. Un volumen de $128 \times 128 \times 38$ con spacing de 3,895 mm no debe marcarse como anómalo sólo por diferir de uno de 256^3 con spacing de 2,46 mm.

Celda 8: familias y scores robustos

Familias de adquisición

Cada firma contiene shape exacto y spacing redondeado a tres decimales:

Esquema

128x128x128|2.460,2.460,2.460

Cada firma recibe un identificador AF001, AF002, etc. “Familia de adquisición” es una estratificación creada para este análisis, cercana a los conceptos de batch, dominio de scanner o protocolo técnico. No es una categoría clínica oficial.

El redondeo a 0,001 mm evita separar archivos por ruido de representación numérica. No implica que el scanner tenga una precisión real de una micra. La regla es deliberadamente trazable, aunque estricta: no captura diferencias de scanner que no se reflejen en shape o spacing y puede fragmentar protocolos parecidos.

Estandarización robusta

Para cada variable se calcula:

$$Z_{robusto} = \frac{x - \text{mediana}(x)}{1.4826 \times MAD(x)},$$

donde:

$$MAD = \text{mediana}(|x - \text{mediana}(x)|).$$

En una distribución normal, $MAD \approx 0.6745 \times \sigma$ y $1/0.6745 \approx 1.4826$. El factor calibra el MAD a la escala aproximada de una desviación estándar normal. No obliga a que los datos sean normales: con distribuciones distintas, el resultado sigue siendo una distancia robusta, pero no debe interpretarse

literalmente como número de desviaciones estándar gaussianas.

Los faltantes se imputan con la mediana. Si el MAD es cero, esa variable no aporta distancia porque no existe dispersión robusta estimable en el grupo.

Score geométrico global

Se construye con cinco variables:

- 1 `log1p(voxel_volume_mm3);`
- 2 `log1p(fov_volume_l);`
- 3 `anisotropía del spacing;`
- 4 `$shape_x/shape_y$;`
- 5 `$shape_z/shape_x$.`

El logaritmo comprime variables positivas sesgadas. Tras obtener sus cinco z robustos:

$$S_{geom} = \sqrt{\frac{z_1^2 + z_2^2 + z_3^2 + z_4^2 + z_5^2}{5}}.$$

Es una distancia geométrica respecto del patrón global de la cohorte.

Score QC dentro del protocolo

Utiliza seis variables:

- 1 `fracción de ceros;`
- 2 `entropía;`
- 3 `$\log(1+\text{componentes de alta captación})$;`
- 4 `fracción del componente más grande;`
- 5 `$\log(1+\text{gradiente por mm})$;`
- 6 `incoherencia axial  $= 1 - \text{correlación entre cortes}$ .`

Para familias con al menos cinco estudios, los z robustos se calculan dentro de la familia. Las familias menores usan la referencia global porque su mediana y MAD serían inestables. Luego:

$$S_{QC} = \sqrt{\frac{z_1^2 + z_2^2 + \dots + z_6^2}{6}}.$$

Score técnico final

Ambos bloques reciben el mismo peso:

$$S_{\text{técnico}} = \sqrt{\frac{S_{\text{geom}}^2 + S_{\text{QC}}^2}{2}}.$$

No existe un umbral clínicamente validado. Un score alto significa técnicamente inusual, no “inválido” ni “patológico”. La tabla ordena los 20 valores mayores para revisión experta.

Celda 9: integridad y gráficos de cohorte

La tabla de integridad informa:

- estudios auditados;
- UID duplicados;
- etiquetas ausentes;
- volúmenes con valores no finitos;
- spacing no positivo;
- afines casi singulares;
- número de familias y familias raras.

Los cuatro gráficos responden preguntas diferentes:

- 1 Spacing X por clase: ¿la etiqueta podría estar asociada al protocolo?
- 2 FOV por familia: ¿existen grupos geométricos definidos?
- 3 Asimetría por clase: ¿el proxy muestra una diferencia descriptiva?
- 4 Gradiente y coherencia: ¿hay estudios especialmente ruidosos o inconsistentes?

Colorear por etiqueta es descriptivo. No interviene en la construcción de los scores. Su utilidad es detectar confusión técnica: un modelo podría aprender resolución o centro de adquisición en vez de biología.

Celda 10: contrato de revisión visual

Aclara que una medición atípica debe contrastarse con la imagen. El ranking selecciona casos para inspeccionar; no reemplaza el juicio visual ni clínico.

Celda 11: visor triplanar y MIP

El visor vuelve a cargar el UID elegido, usa \$p01\$ y \$p99.5\$ como ventana de visualización y localiza un centro de masa aproximado. Presenta:

- sagital;
- coronal;
- axial;
- MIP X, Y y Z.

Una MIP (maximum intensity projection) conserva, para cada posición proyectada, el máximo encontrado a lo largo del eje. Facilita ver la distribución global de captación, pero pierde profundidad.

El UID inicial es el caso con mayor score técnico. La ventana visual no modifica los valores usados en el manifiesto. El selector requiere un kernel activo para cambiar de UID; una copia ejecutada conserva el render inicial, pero no garantiza interactividad sin Jupyter y sus widgets.

Celda 12: contrato de persistencia

Explica que los artefactos derivados son privados y que los NIfTI originales no serán sobrescritos.

Celda 13: persistencia y linaje

Guarda:

Artefacto	Contenido
image_qc_manifest.csv	Una fila de métricas por estudio
image_qc_failures.csv	Archivos que no pudieron procesarse
acquisition_family_summary.csv	Resumen de familias técnicas
image_qc_config.json	Parámetros y contratos utilizados

El JSON registra orientación, definición del gradiente, construcción de familias y ausencia de exclusiones automáticas. Esto permite reproducir y auditar el análisis.

4. Interpretación correcta

El notebook permite afirmar que un estudio:

- tiene cierta geometría y spacing;
- pertenece a una firma técnica observable;
- muestra un comportamiento más o menos inusual;
- merece o no una revisión visual prioritaria.

Por sí solo no permite afirmar que:

- una imagen sea clínicamente inválida;
- un score alto indique Parkinson;
- el foreground corresponda al cerebro completo;
- la división global izquierda/derecha mida asimetría estriatal;
- una familia técnica identifique inequívocamente un scanner o centro.

5. Supuestos y limitaciones

- 1 RAS es necesario, pero insuficiente. Homogeniza ejes; no registra sujetos.
- 2 Shape y spacing son proxies de protocolo. No sustituyen metadatos reales de scanner y centro.
- 3 Los umbrales son relativos. \$p50\$ y \$p90\$ facilitan comparabilidad interna, pero no tienen una

interpretación fisiológica absoluta.

- 1 La asimetría es global. No utiliza regiones anatómicas validadas.
- 2 Los scores usan igual ponderación. Es una decisión exploratoria, no una calibración aprendida.
- 3 El factor 1,4826 usa la normal como referencia de escala. No demuestra normalidad.
- 4 Familias pequeñas usan la cohorte global. Su score QC puede estar más influido por diferencias

de protocolo.

- 1 Un score alto requiere inspección. Nunca justifica exclusión automática.
- 2 El procesamiento prioriza memoria sobre velocidad. Abrir y extraer cada NIfTI por separado

reduce RAM, pero aumenta el tiempo total.

6. Glosario breve

Término	Significado en este notebook
Cohorte completa	Los 1.362 estudios
NIfTI	Contenedor de volumen 3D y metadatos espaciales
Vóxel	Elemento tridimensional de la matriz
Shape	Número de vóxeles por eje
Spacing	Separación física entre vóxeles, en mm
FOV	Cobertura física aproximada del volumen
RAS	Convención derecha-anterior-superior
Affine	Matriz que lleva índices de voxel a coordenadas físicas
Proxy	Medición indirecta o aproximada
QC	Control de calidad técnico
Dominio	Condición técnica de adquisición
MAD	Desviación absoluta mediana
MIP	Proyección de máxima intensidad
Score técnico	Ranking exploratorio de atipicidad, no probabilidad clínica