

Notebook 04

Registro, biomarcadores candidatos y radiomics 3D

Definiciones, supuestos, fórmulas y justificación metodológica

Alcance

Registro físico, fondo robusto con QC, cuantificación relativa, forma, textura 3D, estabilidad y mapas descriptivos para la cohorte.

Contenido

1. Propósito y alcance
2. Terminología fundamental
3. Recorrido celda por celda
4. Interpretación de features
5. Supuestos y limitaciones
6. Glosario breve

Versión metodológica v3 · 26 de agosto de 2026

1. Propósito y alcance

Este documento describe exclusivamente el notebook `notebooks/04_registro_biomarcadores_radiomica.ipynb`. Su función es llevar todos los estudios etiquetados a un espacio físico común, definir regiones de análisis, extraer variables comparables y construir mapas descriptivos por clase.

El notebook responde seis preguntas:

- 1 ¿Cómo hacer comparables estudios con dimensiones y spacing diferentes?
- 2 ¿Cómo alinear cada volumen con una referencia común?
- 3 ¿Qué región se utilizará como objetivo y qué región como fondo?
- 4 ¿Cómo resumir captación, forma y textura tridimensional?
- 5 ¿Cuánto cambian los resultados si se modifica ligeramente la máscara?
- 6 ¿Cómo procesar 1.362 estudios sin conservarlos simultáneamente en memoria?

El flujo conceptual es:

Esquema

```
Manifiesto del notebook 03
|
+-- seleccionar referencia
+-- orientar LPS y remuestrear a 2,5 mm
+-- registrar cada volumen
+-- aplicar atlas o máscara consenso proxy
+-- estimar fondo robusto y su QC
+-- separar cuantificación relativa de mapas de intensidad
+-- extraer captación, forma, textura y estabilidad
+-- actualizar mapas y checkpoints
+-- persistir tablas, mapas y crops
```

El notebook no diagnostica enfermedad y no produce biomarcadores clínicamente validados por sí solo. Cuando no se entrega un atlas validado, las regiones anatómicas son proxies reproducibles contruidos desde la propia cohorte.

2. Terminología fundamental

Registro de imágenes

Registrar dos imágenes significa encontrar una transformación espacial que lleve la imagen móvil al sistema de coordenadas de una imagen fija. El objetivo es que una misma posición represente una zona comparable entre sujetos.

El registro no cambia la etiqueta ni crea señal biológica. Reubica la información mediante una transformación y una interpolación.

Imagen fija, imagen móvil y referencia

- Imagen fija: define el grid y el espacio al que se alinean los estudios.
- Imagen móvil: el estudio que se transforma.
- Referencia: estudio elegido como imagen fija común.

La referencia no representa una verdad anatómica universal. Su elección condiciona el grid, la interpolación y la facilidad del registro. Para una versión definitiva conviene congelar su UID o utilizar un template externo validado.

LPS y relación con RAS

SimpleITK utiliza habitualmente la convención LPS:

- L: izquierda;
- P: posterior;
- S: superior.

El notebook 03 utilizó RAS con nibabel. Ambas convenciones describen coordenadas físicas; cambian los signos de los ejes X e Y. La conversión se realiza usando la información espacial del NIfTI. No se deben comparar arrays de nibabel y SimpleITK ignorando sus affines, direcciones y convenciones.

Isotropía y grid común

Un grid isotrópico tiene el mismo spacing en X, Y y Z. Aquí se utiliza 2,5 mm. El nuevo tamaño se aproxima preservando la cobertura física:

$$N_{nuevo} = \text{round} \left(N_{original} \frac{spacing_{original}}{spacing_{nuevo}} \right).$$

La intensidad se interpola linealmente. Las máscaras se interpolan con vecino más cercano para no crear etiquetas fraccionarias.

Máscara, ROI y atlas

Una máscara es un volumen binario que indica qué vóxeles pertenecen a una región. ROI significa region of interest o región de interés.

Un atlas validado contiene etiquetas anatómicas definidas externamente. Una máscara consenso proxy se estima desde las intensidades de esta cohorte. La segunda es útil para exploración, pero no debe presentarse como segmentación anatómica certificada.

SBR-like

SBR significa specific binding ratio. En el notebook se utiliza una versión aproximada:

$$SBR_{like} = \frac{\bar{I}_{target} - \bar{I}_{fondo}}{\bar{I}_{fondo}} = \frac{\bar{I}_{target}}{\bar{I}_{fondo}} - 1.$$

Se denomina SBR-like porque el fondo y el target pueden provenir de una máscara proxy, no de ROIs clínicas estandarizadas ni de un protocolo de cuantificación validado.

Streaming y checkpoint

Streaming significa procesar un estudio, actualizar los acumuladores y liberar su volumen antes de cargar el siguiente. Un checkpoint es una fotografía persistente del avance que permite continuar después de una interrupción.

3. Recorrido celda por celda

Celda 1: presentación del flujo completo

Declara que se procesarán todos los exámenes etiquetados mediante:

Esquema
cargar -> orientar -> registrar -> extraer -> acumular -> liberar

No se conservan los 1.362 volúmenes simultáneamente en RAM. También establece la jerarquía de máscaras: primero un atlas validado; si no existe, un consenso de controles utilizado como proxy.

Celda 2: contrato de configuración

Indica que los artefactos se guardarán en:

Esquema
outputs/private_edata/full_cohort_v3/

Los notebooks 04 y 05 comparten esta única carpeta. El sufijo v3 congela el nuevo contrato y evita mezclarlo con resultados históricos producidos con otras definiciones. Los checkpoints incluyen features, QC de registro y acumuladores voxel-a-voxel de media y varianza.

Celda 3: bibliotecas, parámetros y rutas

Define las entradas, salidas y decisiones principales.

Parámetro	Significado	Efecto
VALIDATED_MASK_PATH=None	No se configuró atlas	Se construye consenso proxy
MAX_SCANS=None	Sin máximo	Intenta procesar toda la cohorte etiquetada
REFERENCE_UID=None	Referencia automática	Selección determinística
REGISTRATION_MODE='rigid'	Registro rígido	Rotación y traslación, sin deformación
REGISTRATION_BACKEND='torch_cuda'	Backend preferido	Optimización rígida multirresolución en NVIDIA
GPU_FALLBACK_TO_SITK=True	Respaldo del registro	Repite en CPU si CUDA falla o parece poco fiable
ISOTROPIC_SPACING_MM=2.5	Spacing común	Vóxeles de 2,5 mm por eje
MASK_TEMPLATE_SCANS=48	Tamaño máximo del consenso	Hasta 48 controles representativos
TARGET_PERCENTILES=(88,90,92,94)	Umbrales alternativos	Sensibilidad del target
ACTIVE_BACKGROUND_SD=2.0	Umbral de señal activa	Fondo más dos desviaciones estándar
BACKGROUND_SCALE_FLOOR_FRACTION=0.05	Piso del denominador	Al menos 5% del p90 del foreground
MIN_BACKGROUND_VOXELS=64	Soporte mínimo	Exige al menos 64 véxeles para el fondo nominal
MIN_BACKGROUND_SUPPORT_FRACTION=0.20	Cobertura mínima	Exige 20% de la máscara nominal con señal positiva
TEXTURE_LEVELS=32	Discretización	GLCM de 32 niveles
CHECKPOINT_EVERY=20	Frecuencia de guardado	Persistencia cada 20 intentos
RESUME=True	Reanudación	Reutiliza resultados compatibles
RETRY_FAILURES=True	Política de fallos	Reintenta UID fallidos bajo el contrato corregido
SAVE_REGISTERED_CROPS=True	Persistencia de imágenes	Guarda crops normalizados
CROP_MARGIN_MM=20	Contexto alrededor del target	Margen físico de 20 mm

MAX_SCANS=None no limita los estudios. MASK_TEMPLATE_SCANS=48 limita solamente la cantidad usada para construir la máscara consenso.

La celda comprueba que el modo sea rigid o affine, que existan el ZIP y el manifiesto del notebook 03, y crea las carpetas privadas necesarias.

Celda 4: contrato de cohorte y referencia

Aclara que no se excluye automáticamente el 5% técnicamente extremo. Los casos se intentan registrar y los problemas se expresan como fallos o banderas de QC.

La referencia automática se escoge entre controles de la familia de adquisición más frecuente. Esto reduce dos riesgos: elegir una geometría rara y utilizar como referencia un patrón posiblemente muy alterado por la patología.

Celda 5: cohorte etiquetada y selección de referencia

Primero carga `image_qc_manifest.csv` y exige las columnas necesarias del notebook 03. Después:

- 1 conserva sólo estudios con etiqueta disponible;
- 2 convierte la etiqueta a entero;
- 3 ordena determinísticamente por UID;
- 4 si hubiera muestreo, selecciona de forma aproximadamente estratificada por clase.

Con MAX_SCANS=None, el random no actúa.

La familia principal es la que contiene más estudios. Dentro de sus controles se calcula una distancia geométrica usando spacing y FOV estandarizados. A esa distancia se añade el 20% del score QC del notebook 03:

$$S_{referencia} = D_{geometría} + 0.20 S_{QC}.$$

Se elige el menor score. Es una regla de ingeniería reproducible, no una selección clínica. Si no hay controles en la familia principal, utiliza todos los controles; si tampoco existen, utiliza toda la cohorte.

Celda 6: contrato del registro físico

Establece que SimpleITK conservará origen, dirección y spacing durante la lectura y el remuestreo inicial. La referencia se remuestrea a 2,5 mm isotrópicos. La interpolación lineal es apropiada para intensidades continuas; el vecino más cercano se reserva para máscaras discretas. El ajuste rígido residual usa CUDA cuando está disponible y conserva un fallback trazable a SimpleITK/CPU.

Celda 7: lectura LPS, grid isotrópico y registro

Lectura desde el ZIP

Cada NIFTI se extrae temporalmente, se lee como float32, se orienta a LPS y se separa del archivo temporal. Igual que en el notebook 03, procesar uno por uno reduce RAM, pero reabrir el ZIP aumenta el costo de entrada y salida.

Construcción del grid común

`make_isotropic_reference` calcula el tamaño necesario para aproximar la misma extensión física con spacing de 2,5 mm. La referencia isotrópica define tamaño, origen, dirección y spacing para todos los estudios registrados.

Intensidad utilizada por el optimizador

Antes de optimizar, cada imagen se reescala entre 0 y 1. Esta escala se utiliza para el registro; no es la normalización final de biomarcadores.

Registro rígido

El modo predeterminado utiliza una transformación Euler 3D con seis grados de libertad:

- tres traslaciones;
- tres rotaciones.

No cambia tamaños ni formas anatómicas. El modo affine añade escalas y cizallamientos, por lo que es más flexible, pero también puede absorber diferencias que interesa conservar.

Objetivo y optimización

El camino principal GPU optimiza la correlación cruzada normalizada con Adam y seis parámetros rígidos. Trabaja a escalas 0,25, 0,50 y 1,00 con 28, 20 y 12 iteraciones máximas, respectivamente, y detención temprana tras siete iteraciones sin mejora. Los ángulos y desplazamientos normalizados se acotan para impedir transformaciones extremas.

El fallback SimpleITK usa una muestra aleatoria reproducible del 10% de los puntos, descenso de gradiente regularizado y hasta 100 iteraciones por etapa.

El fallback CPU utiliza este esquema multirresolución:

Esquema

Nivel grueso: reducción 4, suavizado 2 mm
Nivel medio: reducción 2, suavizado 1 mm
Nivel fino: reducción 1, suavizado 0 mm

La escala gruesa captura desplazamientos grandes y la fina ajusta detalles. El suavizado se expresa en unidades físicas.

El valor `metric_final_correlation_objective` es el objetivo interno del backend y puede usar una convención de signo orientada a minimización. Para QC son más interpretables `correlation_before` y `correlation_after`, calculadas directamente como correlación de Pearson sobre señal no nula. CUDA se repite automáticamente en CPU si la correlación final no es finita, cae bajo 0,35 o empeora más de 0,03.

$$r = \frac{\sum_i (a_i - \bar{a})(b_i - \bar{b})}{\sqrt{\sum_i (a_i - \bar{a})^2} \sqrt{\sum_i (b_i - \bar{b})^2}}.$$

La referencia no se registra contra sí misma: se asignan correlaciones iguales a uno.

Celda 8: contrato de máscaras

Presenta dos caminos:

- 1 cargar un atlas validado;
- 2 construir un consenso proxy de controles.

El modo utilizado queda registrado en `mask_mode`, evitando presentar el fallback como atlas anatómico.

Celda 9: consenso, target y fondo

Normalización para el consenso

Cada estudio seleccionado se normaliza usando sus percentiles 1 y 99,5, se registra y se incorpora a una media online. La normalización reduce el impacto de escalas absolutas diferentes.

Selección de controles representativos

Se priorizan controles con menor `within_protocol_qc_score` y se reparten cupos entre familias de adquisición. Se usan como máximo 48 y se fuerza la inclusión de la referencia.

La media online se actualiza como:

$$\mu_n = \mu_{n-1} + \frac{x_n - \mu_{n-1}}{n}.$$

Esto evita almacenar los 48 volúmenes registrados simultáneamente.

Máscara target proxy

Sin atlas, el algoritmo:

- 1 conserva el 60% central del volumen en cada eje;
- 2 busca señal positiva por encima del percentil seleccionado, inicialmente p90;
- 3 divide el eje X en dos hemisferios;
- 4 conserva el componente conectado más grande de cada mitad;
- 5 aplica cierre binario y rellena huecos.

En un array SimpleITK la disposición es Z, Y, X. Bajo LPS, los índices X bajos corresponden al lado derecho físico y los altos al izquierdo. Esta relación depende de haber orientado correctamente antes.

El procedimiento busca dos regiones dominantes de alta captación. Es reproducible, pero no identifica por sí mismo caudado y putamen.

Máscara de cerebro y fondo proxy

Se construye soporte con señal superior a p10 y se conserva su mayor componente conectado dentro de un elipsoide central. Este paso evita que el anillo del detector o el aire periférico se conviertan en "fondo". Dentro de una banda posterior de ese soporte cerebral se buscan vóxeles bajo p70, excluyendo una dilatación del target.

Si esa región es pequeña, se usa el soporte cerebral no target bajo p70. La regla sigue siendo una aproximación reproducible y no certifica una ROI occipital clínica.

Atlas validado

Si se configura `VALIDATED_MASK_PATH`, el atlas se orienta a LPS y se remuestrea con vecino más cercano. Se exigen al menos target derecho, target izquierdo y fondo. Opcionalmente puede contener caudado y putamen por lado.

Las máscaras finales y el consenso se guardan en `analysis_masks_full.npz`.

Celda 10: contrato de features

Declara tres familias principales de variables:

- semicuantificación relativa al fondo;
- forma de la región activa;
- textura GLCM realmente tridimensional.

La implementación es reproducible dentro del proyecto, pero aún no ha sido validada contra IBSI. Por eso debe denominarse radiomics exploratoria, no radiomics clínica certificada.

Celda 11: captación, forma, textura y estabilidad

Fondo robusto y normalización semicuantitativa

La máscara de fondo se intersecta con la señal positiva del estudio. Se acepta nominalmente cuando contiene al menos 64 vóxeles y cubre al menos 20% de la ROI de fondo. Si no lo consigue, se buscan en orden: el soporte cerebral no target bajo p70 y la mitad inferior de intensidades positivas. Sobre los valores disponibles se usa una media recortada entre p5 y p95.

Para impedir que un fondo casi nulo genere razones enormes se define:

$$B_{\text{piso}} = 0.05 P90(I_{\text{foreground}}).$$

$$B_{\text{usado}} = \max(\bar{I}_{\text{fondo, recortado}}, B_{\text{piso}}).$$

Para cada estudio registrado, las variables relativas se calculan como:

$$R(x, y, z) = \frac{I(x, y, z)}{B_{\text{usado}}}.$$

Las features relativas usan esta razón. Se guardan además el origen del fondo, soporte, cobertura, media cruda, piso aplicado y `background_qc_valid`. Un fallback o un piso ya no elimina al estudio: lo conserva con una advertencia auditable. El caso sólo falla si ni siquiera existe foreground o fondo robusto mínimo.

Los mapas usan otra escala, independiente del fondo:

$$I_{01}(x, y, z) = \text{clip}\left(\frac{I(x, y, z)}{P99(I_{\text{foreground}})}, 0, 1\right).$$

Separar ambos contratos evita que una ROI de fondo débil domine las medias voxel-a-voxel.

Variables semicuantitativas

Se calculan:

- SBR-like total, derecho e izquierdo;
- menor SBR entre ambos lados;
- asimetría absoluta y con signo;
- razón posterior/anterior;
- media, desviación y percentiles 10, 50 y 90 de la razón target/fondo;
- $\log(1 + \text{target/fondo})$ como resumen comprimido para inspección y modelado robusto.

La asimetría bilateral es:

$$AI_{abs} = \frac{|\bar{I}_L - \bar{I}_R|}{(\bar{I}_L + \bar{I}_R)/2}.$$

Estas variables son candidatas biológicas sólo si las máscaras representan regiones apropiadas. Con consenso proxy conservan explícitamente ese carácter exploratorio.

Región activa y forma

Dentro del target se define señal activa mediante:

$$T_{activo} = \bar{I}_{fondo} + 2SD(I_{fondo}).$$

Se aplica cierre morfológico y se analiza el componente activo más grande. Sus variables incluyen:

- volumen en mililitros;
- superficie en milímetros cuadrados;
- elongación;
- esfericidad;
- extensión dentro de su caja envolvente;
- número de componentes;
- fracción perteneciente al componente principal.

El volumen es:

$$V = N_{\text{vóxeles}} \text{spacing}_x \text{spacing}_y \text{spacing}_z.$$

La elongación se estima desde los autovalores de la covarianza de las coordenadas físicas:

$$E = \sqrt{\frac{\lambda_{max}}{\lambda_{min}}}.$$

La superficie se aproxima mediante marching_cubes. La esfericidad es:

$$\Psi = \frac{\pi^{1/3}(6V)^{2/3}}{A}.$$

Una esfera ideal tiene un valor próximo a uno. La medida depende fuertemente de la máscara, el spacing y la interpolación.

Textura GLCM 3D

Las intensidades relativas dentro del target se recortan robustamente entre p1 y p99 y se cuantizan en 32 niveles. Se cuentan pares de vóxeles vecinos en 13 direcciones 3D y también en su dirección inversa, obteniendo una matriz simétrica de probabilidades $P(i, j)$.

Las variables principales son:

Variable	Definición conceptual
Contraste	Penaliza fuertemente niveles vecinos diferentes
Disimilitud	Diferencia absoluta promedio entre niveles
Homogeneidad	Favorece pares cercanos a la diagonal
Energía	Concentración de la matriz de probabilidades
Entropía	Diversidad o desorden de pares
Correlación	Asociación lineal entre niveles vecinos

Por ejemplo:

$$Contraste = \sum_{i,j} P(i, j)(i - j)^2,$$

$$Energía = \sqrt{\sum_{i,j} P(i,j)^2},$$

$$Entropía = - \sum_{P(i,j) > 0} P(i,j) \log_2 P(i,j).$$

Estas features dependen de la cuantización y la máscara. Sus valores sólo son comparables si se mantiene el mismo contrato.

Sensibilidad y estabilidad

El notebook repite el SBR-like bajo pequeñas perturbaciones:

- 1 target construido con percentiles 88, 90, 92 y 94;
- 2 target erosionado, original y dilatado;
- 3 desplazamientos de un vóxel en X o Y;
- 4 fondo erosionado, original y dilatado.

Para cada familia se guarda el rango:

$$Span = \max(SBR_{like}) - \min(SBR_{like}).$$

Un span pequeño significa que la medida cambia poco ante esa perturbación. Un span alto indica que el resultado depende fuertemente de la máscara, posición o fondo. Es un indicador de fragilidad, no una probabilidad de error.

Celda 12: contrato de streaming y crops

Explica que cada crop comparte el grid de referencia y se guarda en float16 comprimido. Conserva dos representaciones: razón contra fondo para semicuantificación e intensidad I01 para imagen. Esto habilita una futura rama 3D o 2.5D sin conservar el volumen completo.

Celda 13: configuración congelada, reanudación y procesamiento

Hash de configuración

Se serializan referencia, modo de registro, spacing, máscara, umbrales, niveles de textura y hash de UID. Después se calcula SHA-256.

Si existe un checkpoint y el hash no coincide, el notebook se detiene. Esto evita mezclar features producidas con contratos diferentes. El hash protege los parámetros principales, pero no reemplaza un registro completo de versiones de librerías y entorno.

Estado reanudable

Con `RESUME=True` se cargan:

- features existentes;
- QC de registro;
- fallos;
- estado online de mapas.

Los UID cuyo feature, mapa y crop ya quedaron confirmados se omiten. Con `RETRY_FAILURES=True`, los fallos anteriores se vuelven a intentar y desaparecen de la tabla de fallos si luego terminan bien. Los CSV se deduplican por UID, por lo que reanudar no duplica filas.

Actualización online de mapas

Para cada clase se conserva cantidad, media y acumulador $M2$ mediante el algoritmo de Welford:

$$\delta = X_n - \mu_{n-1},$$

$$\mu_n = \mu_{n-1} + \frac{\delta}{n},$$

$$M2_n = M2_{n-1} + \delta(x_n - \mu_n).$$

La varianza muestral posterior es $M2/(n-1)$. Esto permite calcular mapas sin guardar todos los volúmenes en RAM.

Crops registrados

La caja se define alrededor del target más un margen físico de 20 mm. Se guarda:

- volumen razón recortado entre 0 y 20 en `float16`;
- volumen `I01` acotado entre 0 y 1 en `float16`;
- máscara target;
- inicio del crop en Z, Y, X;
- spacing X, Y, Z.

El recorte 0-20 se aplica sólo a los crops persistidos para controlar valores extremos y almacenamiento.

Escritura atómica y checkpoints

Los CSV y el estado se escriben primero en archivos temporales y luego se reemplazan. Esto disminuye el riesgo de dejar archivos parcialmente escritos si el proceso se interrumpe.

Cada estudio se registra, se convierte a array, genera features, actualiza mapas y opcionalmente guarda su crop. Los fallos quedan con UID y excepción. Cada 20 intentos se ejecuta un checkpoint. Si se pulsa `Ctrl+C` o

se produce `SystemExit`, primero se fuerza un checkpoint; ante un corte eléctrico sólo puede repetirse el bloque aún no confirmado, sin duplicar resultados.

Los reemplazos son atómicos y reintentan bloqueos transitorios de Windows/OneDrive. Un crop existente sólo se reutiliza si contiene ambas representaciones esperadas; un archivo truncado se reconstruye.

QC del registro

Se calcula:

$$Ganancia_r = r_{después} - r_{antes}.$$

Se activa `registration_qc_flag` cuando:

- la correlación posterior no es finita;
- la correlación posterior es menor que 0,55;
- la correlación empeora más de 0,05.

Estos umbrales son heurísticos. La bandera no elimina automáticamente el caso ni garantiza que un registro sin bandera sea anatómicamente correcto.

Celda 14: contrato de mapas y efectos

Aclara que las medias son voxel-a-voxel de volúmenes registrados y normalizados por p99 del foreground. No son promedios de MIP ni usan el denominador SBR.

También establece que Cohen d usa varianza agrupada ponderada y que Hedges g corrige su sesgo de muestra pequeña.

Celda 15: mapas, visuales y cobertura

Para cada vóxel se calculan:

$$\Delta = \bar{X}_{patológica} - \bar{X}_{normal}.$$

La varianza agrupada es:

$$s_p^2 = \frac{(n_0 - 1)s_0^2 + (n_1 - 1)s_1^2}{n_0 + n_1 - 2}.$$

Cohen d descriptivo es:

$$d = \frac{\bar{X}_{patológica} - \bar{X}_{normal}}{S_p}.$$

Hedges g aplica la corrección:

$$g = Jd, \quad J \approx 1 - \frac{3}{4(n_0 + n_1) - 9}.$$

Estos mapas muestran tamaño de diferencia estandarizada. No son pruebas de significancia, no incluyen intervalos de confianza y no corrigen comparaciones múltiples entre vóxeles.

Visual de máscaras

El overlay apila tres canales:

Extracto de código

```
R = intensidad del consenso  
G = máscara target  
B = máscara de fondo
```

La combinación intensidad roja más target verde aparece amarilla; el fondo se observa azul o púrpura. Este gráfico permite comprobar posición, cobertura y solapamiento.

Panel descriptivo

Se muestran:

- consenso y overlay de máscaras;
- histograma de correlación posterior al registro;
- $\log(1 + \text{target/fondo robusto})$ por clase;
- media normal y patológica;
- diferencia voxel-a-voxel;
- Hedges g descriptivo.

El corte de máscaras maximiza el área del target. El corte de mapas maximiza la suma del efecto absoluto dentro del target; por tanto, es una selección descriptiva orientada a visualización.

La tabla de cobertura informa denominador solicitado, features obtenidas, fallos, contribuciones por clase a los mapas y banderas de registro. Finalmente se ordenan los veinte casos con mayor sensibilidad a máscara, traslación, umbral o fondo.

Celda 16: contrato de salida

Resume los artefactos producidos:

Artefacto	Contenido
dat_radiomics_features_full.csv	Variables candidatas por estudio
registration_qc_full.csv	Correlaciones, ganancia y bandera técnica
registration_failures_full.csv	UID y error de casos fallidos
streaming_state_full.npz	Media, M2 y conteos reanudables
cohort_maps_full.npz	Medias, diferencia, Cohen d y Hedges g
analysis_masks_full.npz	Consenso y máscaras utilizadas
registered_crops/*.npz	Crops con volume_ratio y volume_intensity01
registration_radiomics_full_config.json	Configuración y hash de compatibilidad

El notebook no elimina casos ni declara las features como biomarcadores clínicamente validados.

4. Cómo interpretar cada bloque de features

Bloque	Pregunta que intenta responder	Principal limitación
Semicuantitativo	¿Cuánta señal relativa existe en target y por lado?	Depende de target y fondo
First-order ratio	¿Cómo se distribuye la intensidad relativa?	Ignora organización espacial
Forma activa	¿Qué volumen y geometría tiene la señal sobre fondo?	Muy sensible al umbral
Textura 3D	¿Cómo se relacionan intensidades vecinas?	Depende de cuantización y máscara
Estabilidad	¿Cuánto cambia el resultado ante perturbaciones?	Perturbaciones limitadas y heurísticas
QC de registro	¿El alineamiento parece razonable numéricamente?	Correlación no garantiza anatomía

Las variables técnicas de registro y dominio deben mantenerse separadas de las variables biológicas al evaluar modelos. Pueden servir para auditoría, estratificación y análisis de confusión.

5. Supuestos y limitaciones

- Una referencia individual es suficiente para este análisis exploratorio, pero puede introducir sesgo de template.
- El registro rígido conserva forma, pero no corrige diferencias anatómicas locales.
- La interpolación modifica suavemente intensidades y textura.
- Un consenso de captación no equivale a un atlas anatómico.
- La región de fondo cerebral/posterior es una regla proxy dependiente de orientación y señal.
- El piso del denominador estabiliza razones, pero cambia su interpretación cuando se activa; por eso se persisten `background_floor_applied` y `background_qc_valid`.
- SBR-like no es una cuantificación clínica certificada.
- La forma activa depende del umbral fondo más dos desviaciones estándar.
- La GLCM es 3D y reproducible, pero todavía no está verificada contra IBSI.
- Los spans evalúan cuatro perturbaciones concretas; no cubren toda la incertidumbre posible.
- Las banderas de registro y los criterios de fallback usan umbrales heurísticos.
- Cohen d y Hedges g son descriptivos, no inferencia voxel-a-voxel.
- El hash de configuración no captura automáticamente todas las versiones del entorno.
- Procesar desde un ZIP limita memoria, pero aumenta el tiempo de entrada y salida.
- La persistencia limita la pérdida de trabajo; no puede guardar una operación que estaba a mitad de cálculo durante un corte abrupto.

6. Glosario breve

Término	Significado en este notebook
Registro	Alineamiento espacial de una imagen móvil con una fija
Referencia	Imagen que define el grid común
LPS	Convención izquierda-posterior-superior
Isotrópico	Mismo spacing en X, Y y Z
Interpolación lineal	Estimación continua usada para intensidades
Vecino más cercano	Interpolación discreta usada para etiquetas
ROI	Región de interés
Atlas	Volumen externo con etiquetas anatómicas
Consenso	Media de controles registrados y normalizados
SBR-like	Razón de unión específica aproximada
GLCM	Matriz de coocurrencia de niveles de gris
Streaming	Procesamiento secuencial con memoria acotada
Checkpoint	Estado persistente que permite reanudar
Crop	Subvolumen alrededor del target
Welford	Algoritmo online de media y varianza
Cohen d	Diferencia estandarizada descriptiva
Hedges g	Cohen d con corrección de muestra pequeña
QC flag	Bandera de revisión, no exclusión automática